

Formulario dettagliato

Capitolo 06 — Fondamenti di Machine Learning

Questo capitolo riassume i concetti, le formule e le ricette operative fondamentali per affrontare problemi di apprendimento supervisionato (regressione e classificazione), con particolare attenzione a: definizioni di errore, bias–variance, learning curves, overfitting, regolarizzazione, validazione (cross-validation), metodi di ottimizzazione (gradient descent), regressione logistica, e legami tra MLE e LS.

6.1 Problema di apprendimento supervisionato — notazione di base

- Dati di training: $\mathcal{D} = \{(\phi_i, y_i)\}_{i=1}^N$, con $\phi_i \in \mathbb{R}^d$ vettori di feature e y_i target (reale per regressione, discreto per classificazione).
- Spazio delle ipotesi: $\mathcal{H} = \{h(\cdot; \theta)\}$, parametro $\theta \in \mathbb{R}^p$.
- Obiettivo: trovare $h \in \mathcal{H}$ che minimizzi l'errore **out-of-sample**.

Errore in-sample (training)

$$E_{\text{in}}(\theta) = \frac{1}{N} \sum_{i=1}^N \ell(y_i, h(\phi_i; \theta))$$

Errore out-of-sample (generalizzazione attesa)

$$E_{\text{out}}(h) = \mathbb{E}_{\phi, y} [\ell(y, h(\phi))]$$

Scopo pratico: stimare E_{out} tramite metodi di validazione e scegliere modello/ipерparametri che minimizzino E_{out} .

6.2 Bias–Variance decomposition (intuito + formula)

Consideriamo la previsione $\hat{g}_{\mathcal{D}}(\phi)$ ottenuta da un algoritmo che usa dataset $\mathcal{D}$. Fissato un punto ϕ , e assumendo $y = f(\phi) + \eta$ con rumore η zero-mean e $\text{Var}(\eta) = \sigma^2$, si ha:

Decomposizione del MSE atteso (per un dato ϕ)

$$\mathbb{E}_{\mathcal{D}, \eta}[(\hat{g}_{\mathcal{D}}(\phi) - y)^2] = \underbrace{(\mathbb{E}_{\mathcal{D}}[\hat{g}_{\mathcal{D}}(\phi)] - f(\phi))^2}_{\text{bias}^2(\phi)} + \underbrace{\mathbb{E}_{\mathcal{D}}[(\hat{g}_{\mathcal{D}}(\phi) - \mathbb{E}_{\mathcal{D}}[\hat{g}_{\mathcal{D}}(\phi)])^2]}_{\text{variance}(\phi)} + \underbrace{\sigma^2}_{\text{rumore irreducibile}}$$

Significato pratico

- Bias: errore medio dovuto alla limitata capacità di $\mathcal{H}$ di approssimare f .
- Varianza: sensitività dell'algoritmo ai dati campionati.
- Rumore: non rimovibile con nessun modello.

Regola operativa: modelli più complessi tendono ad avere bias basso ma varianza alta; regolarizzazione e più dati riducono varianza.

6.3 Learning curves — interpretazione pratica

- Le learning curves mostrano E_{in} e stima di E_{out} in funzione della dimensione del training set N .
 - Interpretazione:
 - Se $E_{\text{in}} \approx E_{\text{out}}$ e alto $\Rightarrow$ **alto bias** $\rightarrow$ servono modelli più complessi o features migliori.
 - Se $E_{\text{in}} \ll E_{\text{out}}$ $\rightarrow$ **alta varianza** $\rightarrow$ servono più dati, regolarizzazione o modelli meno complessi.
-

6.4 Overfitting / Underfitting — rimedi pratici

- **Overfitting:** buon fit su training, scarsa generalizzazione. Rimedi: regolarizzazione, ridurre complessità, più dati, data augmentation, ensemble (bagging).
 - **Underfitting:** modello troppo semplice $\rightarrow$ aumentare complessità (features non lineari, polinomi, modelli più ricchi).
-

6.5 Regolarizzazione — formulazione e soluzioni chiuse

Ridge regression (L_2) — problema di regressione lineare:

- Modello lineare: $y = \Phi\theta + \varepsilon$, con $\Phi \in \mathbb{R}^{N \times d}$ matrice dei regressori.
- Funzione costo con penalità:

$$J_{\text{ridge}}(\theta) = \frac{1}{N} \|y - \Phi\theta\|_2^2 + \lambda \|\theta\|_2^2$$

- Soluzione chiusa:

$$\hat{\theta}_{\text{ridge}} = (\Phi^\top \Phi + N\lambda I)^{-1} \Phi^\top y$$

(N.B.: alcune notazioni assorbono N dentro λ .)

Lasso (L_1)

$$J_{\text{lasso}}(\theta) = \frac{1}{N} \|y - \Phi\theta\|_2^2 + \lambda \|\theta\|_1$$

- Non ha soluzione chiusa; si risolve con algoritmi iterativi (coordinate descent, proximal methods). Favorisce sparse solutions.

Elastic-net: combinazione L_1 e L_2 :

$$\Omega(\theta) = \alpha \|\theta\|_1 + (1 - \alpha) \|\theta\|_2^2$$

Interpretazione bayesiana (utile per collegamenti)

Ridge = MAP con prior gaussiano $\theta \sim \mathcal{N}(0, \tau^2 I)$ (la penalità L_2 corrisponde a prior normale). Questo collega regolarizzazione e stima Bayesiana (vedi Capitolo 07).

6.6 Stima a massima verosimiglianza (MLE) e minimi quadrati (LS)

Modello lineare Gaussiano: $y = \Phi\theta + \varepsilon$, $\varepsilon \sim \mathcal{N}(0, \sigma^2 I)$.

Likelihood

$$p(y|\theta) = (2\pi\sigma^2)^{-N/2} \exp\left(-\frac{1}{2\sigma^2} \|y - \Phi\theta\|^2\right)$$

MLE (massimizza la likelihood) equivalgono ai minimi quadrati:

$$\hat{\theta}_{ML} = \arg \min_{\theta} \|y - \Phi\theta\|^2 \quad \Rightarrow \quad \hat{\theta}_{ML} = (\Phi^\top \Phi)^{-1} \Phi^\top y \quad (\text{se invertibile})$$

Varianza dello stimatore

$$\text{Cov}(\hat{\theta}_{ML}) = \sigma^2 (\Phi^\top \Phi)^{-1}$$

6.7 Algoritmi numerici: gradient descent e Newton

Gradient descent (batch) per $J(\theta) = \frac{1}{N} \|y - \Phi\theta\|^2$:

- Gradiente:

$$\nabla_{\theta} J = -\frac{2}{N} \Phi^{\top} (y - \Phi \theta)$$

- Aggiornamento iterativo:

$$\theta^{(k+1)} = \theta^{(k)} - \eta \nabla_{\theta} J(\theta^{(k)})$$

(dove η è il learning rate).

Newton / IRLS (per funzioni non quadratiche): update basato su Hessiana:

$$\theta^{(k+1)} = \theta^{(k)} - H^{-1}(\theta^{(k)}) \nabla J(\theta^{(k)})$$

utile per problemi logistic / GLM (vedi sezione successiva).

6.8 Regressione logistica (classificazione binaria)

Modello

- $p(y = 1 | \phi; \theta) = \sigma(\phi^{\top} \theta)$, con $\sigma(a) = \frac{1}{1+e^{-a}}$ (sigmoide).
- Log-likelihood su dati i.i.d.:

$$\ell(\theta) = \sum_{i=1}^N [y_i \log \sigma(\phi_i^{\top} \theta) + (1 - y_i) \log(1 - \sigma(\phi_i^{\top} \theta))]$$

Gradiente

$$\nabla \ell(\theta) = \sum_{i=1}^N (y_i - \sigma(\phi_i^{\top} \theta)) \phi_i = \Phi^{\top} (y - \hat{p})$$

dove $\hat{p}_i = \sigma(\phi_i^{\top} \theta)$.

Hessiana

$$H(\theta) = -\Phi^{\top} R \Phi, \quad R = \text{diag}(\hat{p}_i(1 - \hat{p}_i))$$

Aggiornamento Newton / IRLS

$$\theta^{(k+1)} = \theta^{(k)} + (\Phi^{\top} R \Phi)^{-1} \Phi^{\top} (y - \hat{p})$$

Regolarizzazione si ottiene aggiungendo $\lambda \|\theta\|_2^2$ e alterando Hessiana/gradiente.

6.9 Validazione & Cross-validation (pratiche)

- **Hold-out**: dividere i dati in training / validation / test.
- **K-fold CV**: dividere in K partizioni; per ogni fold si usa $K - 1$ per training e 1 per validation; la stima CV è la media:

$$\hat{E}_{CV} = \frac{1}{K} \sum_{k=1}^K E_{\text{val}}^{(k)}$$

- **LOOCV**: caso $K = N$ (leave-one-out); può essere molto costoso ma ha bassa varianza in certi casi.
 - Scegli modello/ipерparametri minimizzando $\hat{E}_{CV}$.
-

6.10 Raccomandazioni pratiche (estratte e riassunte dalle slide)

- Sempre **depola** i dati (rimuovi media) quando appropriato.
 - Esamina **ACF/PACF** per serie temporali (se rilevante).
 - Usa **regularization** per combattere overfitting; scegli λ via CV.
 - Per modelli lineari, preferisci Ridge (chiuso) se vuoi stabilità numerica; Lasso per sparsity.
 - Per classificazione, preferisci regolarizzazione L2 per stabilità; L1 per feature selection.
-

Capitolo 07 — Fondamenti di stima Bayesiana

Questo capitolo raccoglie il formalismo bayesiano: definizioni (prior, likelihood, posterior), stime puntuali (MAP, MMSE), esempi coniugati (Beta–Bernoulli), il caso gaussiano lineare (posteriors gaussiani), la stima ottima lineare e la connessione con il filtro di Kalman.

7.1 Teorema di Bayes — definizione centrale

Per parametri θ e dati osservati Y :

$$p(\theta|Y) = \frac{p(Y|\theta) p(\theta)}{p(Y)} \quad \text{dove} \quad p(Y) = \int p(Y|\theta) p(\theta) d\theta$$

- $p(\theta)$ = **prior** (informazione a-priori su θ).

- $p(Y|\theta)$ = **likelihood** (informazione portata dai dati).
 - $p(\theta|Y)$ = **posterior** (credence aggiornata su θ).
 - $p(Y)$ = marginal likelihood (evidence) — utile per selezione modello.
-

7.2 Scelte puntuali dalla posterior (MAP, MMSE, mediana)

- **MAP (Maximum A Posteriori):**

$$\hat{\theta}_{\text{MAP}} = \arg \max_{\theta} p(\theta|Y) = \arg \max_{\theta} \{ \log p(Y|\theta) + \log p(\theta) \}$$

- **MMSE (Bayes estimator sotto MSE):** minimizza l'errore quadratico atteso, è la **media a-posteriori**:

$$\hat{\theta}_{\text{MMSE}} = \mathbb{E}[\theta|Y]$$

- **Nota:** se la posterior è gaussiana, media = moda = mediana, quindi MAP = MMSE.
-

7.3 Esempio coniugato: Beta–Bernoulli (moneta)

- Dati: $y_i \sim \text{Bernoulli}(\pi)$, $i = 1, \dots, N$. Successi $S = \sum y_i$.
- Prior coniugato: $\pi \sim \text{Beta}(\alpha, \beta)$ con pdf

$$p(\pi) \propto \pi^{\alpha-1} (1 - \pi)^{\beta-1}$$

- Posterior (coniugata):

$$\pi|y \sim \text{Beta}(\alpha + S, \beta + N - S)$$

Stime:

- Posterior mean (MMSE):

$$\mathbb{E}[\pi|y] = \frac{\alpha + S}{\alpha + \beta + N}$$

- MAP (modalità della Beta):

$$\hat{\pi}_{\text{MAP}} = \frac{\alpha + S - 1}{\alpha + \beta + N - 2} \quad (\text{se } \alpha + S > 1 \text{ e } \beta + N - S > 1)$$

Interpretazione: il prior “aggiunge” pseudo-successi e pseudo-fallimenti, regolarizzando la stima.

7.4 Caso gaussiano lineare (prior gaussiano + likelihood gaussiana) — formula chiave

Modello:

$$y = \Phi\theta + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2 I)$$

Prior su θ gaussiano:

$$\theta \sim \mathcal{N}(\mu_0, \Sigma_0)$$

Allora la posterior è gaussiana: $\theta|y \sim \mathcal{N}(\mu_n, \Sigma_n)$ con

Posterior precision / covarianza

$$\Sigma_n = \left(\Sigma_0^{-1} + \frac{1}{\sigma^2} \Phi^\top \Phi \right)^{-1}$$

Posterior mean

$$\mu_n = \Sigma_n \left(\Sigma_0^{-1} \mu_0 + \frac{1}{\sigma^2} \Phi^\top y \right)$$

Interpretazione

- La precisione a-posteriori è la somma della precisione prior Σ_0^{-1} e della precisione informativa dei dati $(1/\sigma^2)\Phi^\top \Phi$.
- MAP = μ_n (nel caso gaussiano la media coincide con la moda).

Collegamento a Ridge

Se $\mu_0 = 0$ e $\Sigma_0 = \tau^2 I$, allora la MAP risolve:

$$\hat{\theta}_{\text{MAP}} = \arg \min_{\theta} \frac{1}{2\sigma^2} \|y - \Phi\theta\|^2 + \frac{1}{2\tau^2} \|\theta\|^2,$$

che è equivalente alla ridge con $\lambda = \sigma^2/\tau^2$.

7.5 Stimatori ottimi e perdite — perché scegliere la media o la moda

- **MSE (quadratico)** → minimizzatore: posterior mean (MMSE).
 - **0–1 loss** (classificazione) → minimizzatore: posterior mode / Bayes decision rule appropriata.
 - In pratica: scegli la regola di decisione coerente con il criterio di performance che userai (MSE, error rate, cost-sensitive, ecc.).
-

7.6 Stima ottima lineare — formula generale e connessione con Kalman

Caso generale lineare-gaussiano: supponiamo $\theta \sim \mathcal{N}(\mu_\theta, \Sigma_\theta)$ e osservazioni

$$Y = H\theta + \eta, \quad \eta \sim \mathcal{N}(0, \Sigma_\eta)$$

Stima condizionata (formule note)

$$\mathbb{E}[\theta|Y] = \mu_\theta + \Sigma_\theta H^\top (H \Sigma_\theta H^\top + \Sigma_\eta)^{-1} (Y - H\mu_\theta)$$

Forma equivalente (guadagno di Kalman):

- Definire guadagno $K = \Sigma_\theta H^\top (H \Sigma_\theta H^\top + \Sigma_\eta)^{-1}$, allora

$$\hat{\theta} = \mu_\theta + K(Y - H\mu_\theta)$$

Connessione con il filtro di Kalman:

- In problemi dinamici (stato che evolve nel tempo), le formule di aggiornamento della stima a posteriori quando arriva un nuovo dato sono ricorsive e usano esattamente un termine di guadagno (Kalman gain).
 - Le equazioni del filtro nascono dal caso gaussiano lineare applicato in forma ricorsiva (predizione + aggiornamento).
-

7.7 Recursive update (intuizione operativa)

Dai risultati gaussiani, la precisione a-posteriori soddisfa:

$$\Sigma_n^{-1} = \Sigma_0^{-1} + \frac{1}{\sigma^2} \Phi^\top \Phi$$

Questa somma di precisioni è alla base degli aggiornamenti ricorsivi (si possono usare formule tipo Sherman–Morrison per aggiornare inversi in tempo reale). In pratica:

- appena arriva un nuovo dato (ϕ_t, y_t) si aggiorna la media e la covarianza senza riesaminare tutti i dati: schema predizione + aggiornamento (Kalman-like).
-

7.8 Model evidence & selezione modello (nota rapida)

- Marginal likelihood (evidence):

$$p(y) = \int p(y|\theta)p(\theta)d\theta$$

- Permette confrontare modelli (Bayes factors). In pratica, il calcolo esatto può essere costoso; si usano approssimazioni (Laplace), criteri informativi (BIC), o cross-validation.
-

7.9 Raccomandazioni pratiche tratte dalle slide

- Se hai conoscenza pregressa, codificala in un prior informativo; altrimenti usa priors deboli/coniugati per stabilità.
 - Per il modello lineare gaussiano, il calcolo è analitico e stabile: sfruttalo per interpretabilità.
 - Per modelli complessi (non coniugati), usare MCMC o VB per approssimare la posterior.
 - Ricorda il legame tra Bayes MAP e regolarizzazione: il bayesiano dà una motivazione principled per i termini di penalità (prior).
-

Processi stocastici (Lez.08) + Famiglie di modelli (Lez.09)

Questa versione espande il formulario precedente: ogni formula è seguita da spiegazione del significato, quando e come si usa, proprietà pratiche e riferimenti operativi tratti dalle slide.

1) Notazione e primi concetti

- Indicheremo con $v(t, s)$ il processo stocastico al tempo t e per esito s ; spesso scriviamo semplicemente $v(t)$ quando la dipendenza da s è implicita.
 - Una *realizzazione* (o *path*) è $v(t, s = \bar{s})$: è la serie temporale osservata.
-

2) Valore atteso (media) e sua stima

Definizione teorica (media di insieme)

$$m_v = \mathbb{E}_s[v(t, s)]$$

Significato

- m_v è la media (tendente centrale) del processo: valore atteso *alla stessa istante* su tutte le realizzazioni possibili (ensemble).
- È **indipendente da t** se il processo è stazionario (in senso debole).

Stima pratica (media temporale su una realizzazione)

$$\bar{v}_N = \frac{1}{N} \sum_{t=0}^{N-1} v(t)$$

Quando usarla / proprietà

- $\bar{v}_N$ è lo stimatore che usiamo quando abbiamo **una sola serie** lunga.
- Se il processo è **ergodico nella media**, allora

$$\lim_{N \rightarrow \infty} \bar{v}_N = m_v \quad (\text{quasi certamente}).$$

- In pratica: si depolarizza la serie sottraendo $\bar{v}_N$ prima di calcolare autocovarianze/PSD.
-

3) Autocovarianza e autocorrelazione

Autocovarianza (per pss, dipende solo dal lag τ)

$$\gamma_{vv}(\tau) = \mathbb{E}[(v(t) - m_v)(v(t + \tau) - m_v)]$$

Autocorrelazione normalizzata

$$\rho_{vv}(\tau) = \frac{\gamma_{vv}(\tau)}{\gamma_{vv}(0)}$$

Significato

- Misura la dipendenza lineare del processo fra due istanti separati di τ campioni.
- $\gamma_{vv}(0)$ è la varianza del processo.
- Se $\gamma_{vv}(\tau)$ è alto per τ grandi $\rightarrow$ il processo ha “memoria lunga”; se tende a 0 rapidamente $\rightarrow$ “dimentica” velocemente.

Proprietà utili

- $\gamma_{vv}(0) \geq 0$.
 - $|\gamma_{vv}(\tau)| \leq \gamma_{vv}(0)$.
 - $\gamma_{vv}(\tau) = \gamma_{vv}(-\tau)$ (pari).
-

4) Stimatori campionari della media e dell'autocovarianza (pratica)

Media campionaria

$$\bar{v}_N = \frac{1}{N} \sum_{t=0}^{N-1} v(t)$$

- Consistente sotto ergodicità.

Stimatore "non distorto" dell'autocovarianza (usato nelle teorie; denominatore $N - \tau$)

$$\hat{\gamma}_{vv}(\tau) = \frac{1}{N - \tau} \sum_{t=0}^{N-\tau-1} (v(t) - \bar{v}_N) (v(t + \tau) - \bar{v}_N), \quad 0 \leq \tau < N$$

Stimatore alternativo (più comune in calcolo numerico: denominatore N)

$$\hat{\gamma}'_{vv}(\tau) = \frac{1}{N} \sum_{t=0}^{N-\tau-1} (v(t) - \bar{v}_N) (v(t + \tau) - \bar{v}_N)$$

Differenze e proprietà

- $\hat{\gamma}_{vv}(\tau)$ è *non distorto* (cioè $\mathbb{E}[\hat{\gamma}_{vv}(\tau)] = \gamma_{vv}(\tau)$) salvo effetti dovuti a $\bar{v}_N$; tuttavia la varianza di questo stimatore cresce per τ grande perché il numero di termini è $N - \tau$.
- $\hat{\gamma}'_{vv}(\tau)$ è **biased**:

$$\mathbb{E}[\hat{\gamma}'_{vv}(\tau)] = \frac{N - \tau}{N} \gamma_{vv}(\tau),$$

ma ha **varianza più piccola** per τ grandi (utile in pratica).

- Entrambi sono *consistenti* per $N \rightarrow \infty$ a τ fissato (sotto ipotesi di ergodicità).

Pratica

- Per stime robuste su dataset finiti, spesso si usa la versione con denominatore N (più stabile numericamente), oppure si applicano finestre sui lag (Blackman–Tukey).
-

5) Ergodicità — cosa garantisce

Ergodicità nella media

$$\lim_{N \rightarrow \infty} \frac{1}{N} \sum_{t=0}^{N-1} v(t) = m_v \quad (\text{q.c.})$$

Condizioni sufficienti (slide)

- $\gamma_{vv}(0) < \infty$ (varianza finita);
- $\lim_{\tau \rightarrow \infty} \gamma_{vv}(\tau) = 0$ (la memoria si annulla).

Significato pratico

- Se il processo è ergodico, *una sola* realizzazione lunga è sufficiente per stimare i parametri ensemble (media, autocovarianza, PSD).
 - Se non si può dimostrare l'ergodicità, spesso la si *assume* per procedere con stime temporali.
-

6) Trasformata $\mathcal{Z}$ e DTFT — definizioni e uso

Trasformata $\mathcal{Z}$ bilatera

$$G(z) = \mathcal{Z}\{g(t)\} = \sum_{t=-\infty}^{+\infty} g(t) z^{-t}, \quad z \in \mathbb{C}$$

DTFT (trasformata di Fourier a tempo discreto)

$$G(e^{j\omega}) = \sum_{t=-\infty}^{+\infty} g(t) e^{-j\omega t}$$

- Si ottiene valutando la $\mathcal{Z}$ sulla circonferenza unitaria $z = e^{j\omega}$.

Significato / uso

- La $\mathcal{Z}$ è lo strumento per analizzare sistemi LTI discreti: si usano polinomi in z^{-1} per rappresentare filtri e sistemi.
- La DTFT è usata per studiare la risposta in frequenza (modulo/fase) per segnali/processi discreti.

Nota su ROC e stabilità

- La $\mathcal{Z}$ converge solo in una regione di convergenza (ROC). Per sistemi causali e stabili, la ROC è esterna al polo più esterno (forma pratica: poli all'interno della circonferenza unitaria implicano stabilità).
 - In pratica, per processi stazionari ci interessa valutare su $|z| = 1$ (DTFT).
-

7) Densità spettrale di potenza (PSD) — definizione e inversione

Definizione (DTFT di γ)

$$\Gamma_{vv}(\omega) = \sum_{\tau=-\infty}^{+\infty} \gamma_{vv}(\tau) e^{-j\omega\tau}$$

Inversione (autocovarianza dalla PSD)

$$\gamma_{vv}(\tau) = \frac{1}{2\pi} \int_{-\pi}^{\pi} \Gamma_{vv}(\omega) e^{j\omega\tau} d\omega$$

Varianza come area sotto la PSD

$$\gamma_{vv}(0) = \frac{1}{2\pi} \int_{-\pi}^{\pi} \Gamma_{vv}(\omega) d\omega$$

Significato

- La PSD dice come la varianza del processo è ripartita tra le frequenze: picchi della PSD indicano frequenze dominanti.
- Proprietà: $\Gamma_{vv}(\omega)$ è reale, pari e non-negativa.

Esempio: rumore bianco

- Se $e(t) \sim \text{WN}(0, \lambda^2)$ allora

$$\gamma_{ee}(\tau) = \lambda^2 \delta_{\tau,0} \quad \Rightarrow \quad \Gamma_{ee}(\omega) = \lambda^2 \quad (\text{costante})$$

- Quindi il white noise ha PSD piatta (tutte le frequenze contengono la stessa potenza).
-

8) Stima della PSD: periodogramma e metodi avanzati

Periodogramma (definizione)

$$I_N(\omega) = \frac{1}{N} \left| \sum_{t=0}^{N-1} v(t) e^{-j\omega t} \right|^2$$

Proprietà pratiche

- $I_N(\omega)$ è uno **stimatore non consistente** in senso di varianza (la varianza non tende a 0 per $N \rightarrow \infty$), e può essere molto rumoroso.
- L'aspettazione $\mathbb{E}[I_N(\omega)]$ è una versione “smoothed” della PSD vera: quindi il periodogramma è **bias-variable** — dipende dall’“effetto finestra” implicito.

Strategie di miglioramento

- **Welch / Bartlett**: dividere la serie in segmenti (con eventuale overlap e finestrazione), calcolare periodogramma su ogni segmento e fare la media. Riduce la varianza (proporzionalmente al numero di segmenti) ma peggiora la risoluzione in frequenza.
- **Blackman–Tukey**: stimare prima $\hat{\gamma}(\tau)$, applicare una finestra sui lag (per tagliare l'incertezza sui lag lontani) e poi calcolare la DTFT di quel $\hat{\gamma}(\tau)$ finestrato. Permette di controllare esplicitamente lo smoothing in frequenza (trade-off bias/varianza).

Leakage & finestrazione

- La scelta della finestra (rectangular, Hamming, Hann, Blackman, ecc.) governa il compromesso tra **main-lobe width** (risoluzione) e **side-lobe level** (leakage).

9) Sistemi LTI discreti e relazioni spettrali ingresso–uscita

Convoluzione (tempo)

$$y(t) = \sum_{k=0}^{\infty} g_k u(t - k)$$

Funzione di trasferimento ($\mathcal{Z}$)

$$G(z) = \sum_{k=0}^{\infty} g_k z^{-k}, \quad Y(z) = G(z) U(z)$$

Relazione PSD (ingresso stocastico)

- Cross-spettro ingresso–uscita:

$$\Gamma_{yu}(\omega) = G(e^{j\omega}) \Gamma_{uu}(\omega)$$

- PSD di uscita:

$$\Gamma_{yy}(\omega) = |G(e^{j\omega})|^2 \Gamma_{uu}(\omega) \quad (\text{se ingresso e rumore sono non correlati})$$

Significato pratico

- Il sistema “filtra” la potenza dell'ingresso: frequenze dove $|G|^2$ è grande vengono amplificate nella PSD di uscita.

10) Famiglie di modelli stocastici (Lezione 09) — definizioni, formule e significato

Qui riportiamo le forme canoniche usate nelle slide e il loro ruolo nel descrivere processi e sistemi.

10.1) MA — Moving Average (ordine n_c)

Definizione tempo

$$y(t) = \sum_{i=0}^{n_c} c_i e(t-i) \quad (\text{di norma } c_0 = 1 \text{ per fissare scala})$$

Forma $\mathcal{Z}$

$$Y(z) = C(z) E(z), \quad C(z) = \sum_{i=0}^{n_c} c_i z^{-i}$$

Autocovarianza

$$\gamma_{yy}(\tau) = \sigma_e^2 \sum_{i=0}^{n_c-\tau} c_i c_{i+\tau}, \quad 0 \leq \tau \leq n_c$$

e $\gamma_{yy}(\tau) = 0$ per $\tau > n_c$.

Significato / uso

- Modella processi "a memoria finita": l'autocovarianza si annulla dopo n_c lag.
- Utile per fenomeni dove solo pochi ritardi del rumore influenzano l'uscita.

10.2) AR — AutoRegressive (ordine n_a)

Definizione tempo

$$y(t) = \sum_{i=1}^{n_a} a_i y(t-i) + e(t)$$

Forma $\mathcal{Z}$

$$\underbrace{(1 - a_1 z^{-1} - \dots - a_{n_a} z^{-n_a})}_{A(z)} Y(z) = E(z) \Rightarrow Y(z) = \frac{1}{A(z)} E(z)$$

Condizione di stazionarietà / stabilità

- Il processo è stazionario se **tutti i poli** (soluzioni di $A(z) = 0$) hanno modulo < 1 (cioè si trovano all'interno della circonferenza unitaria nel piano z).
- Esempio AR(1): $y(t) = a_1 y(t-1) + e(t)$ è stazionario se $|a_1| < 1$.

Equazioni di Yule–Walker (relazione tra γ e a_i)

Per $\tau \geq 0$:

$$\gamma_{yy}(\tau) = \sum_{i=1}^{n_a} a_i \gamma_{yy}(\tau-i) + \sigma_e^2 \delta_{\tau,0}$$

Significato / uso

- Modelli con memoria potenzialmente infinita (MA^∞).
- La PACF (partial autocorrelation) si annulla dopo ordine n_a , utile per selezione d'ordine.

10.3) ARMA (ordine n_a, n_c)

Definizione

$$\underbrace{A(z)}_{AR} Y(z) = \underbrace{C(z)}_{MA} E(z) \Rightarrow Y(z) = \frac{C(z)}{A(z)} E(z)$$

dove $A(z) = 1 - \sum_{i=1}^{n_a} a_i z^{-i}$ e $C(z) = \sum_{i=0}^{n_c} c_i z^{-i}$.

Significato

- Combina le due dinamiche: parte autoregressiva e parte media mobile.
- Un ARMA stazionario può essere espresso come $MA(\infty)$ (espansione in serie geometrica), se $A(z)$ è invertibile.

10.4) Modelli ingresso–uscita (ARX, ARMAX, OE, BJ)

ARX (AutoRegressive with eXogenous input)

$$A(z) y(t) = z^{-k} B(z) u(t) + e(t)$$

- $B(z) = \sum b_j z^{-j}$; k = ritardo puro (dead-time).
- $H(z) = \frac{B(z)z^{-k}}{A(z)}$ è la dinamica ingresso→uscita, rumore additivo bianco $e(t)$.

ARMAX

$$A(z) y(t) = z^{-k} B(z) u(t) + C(z) e(t)$$

- Qui il rumore è modellato con $C(z)$ (parte MA). Migliora modellazione se il rumore non è bianco.

OE (Output Error)

$$y(t) = \frac{B(z)}{F(z)} z^{-k} u(t) + e(t)$$

- Il rumore $e(t)$ entra *dopo* la dinamica: utile quando l'unico errore è di misura in uscita.

Box–Jenkins (BJ)

$$y(t) = \frac{B(z)}{F(z)} z^{-k} u(t) + \frac{C(z)}{D(z)} e(t)$$

- Massima flessibilità: dinamica ingresso-output e modello del rumore parametrizzati indipendentemente.

Quando scegliere cosa

- ARX: semplice, utile se rumore $\approx$ bianco. Stima lineare (LS) efficiente.
- ARMAX / BJ: se il rumore ha struttura, miglior accuratezza, ma identificazione più complessa (non sempre LS diretto).
- OE: preferito quando rumore è solo misurazione e non è filtrato dalla dinamica.

11) Relazioni tra PSD e modelli (uso operativo)

- Per un modello $Y(z) = \frac{C(z)}{A(z)} E(z)$ con E white noise σ_e^2 , la PSD è:

$$\Gamma_{yy}(\omega) = |C(e^{j\omega})/A(e^{j\omega})|^2 \sigma_e^2$$

- Questo è utile per: riconoscere se i dati hanno una risonanza (poli vicini alla circonferenza unitaria), per scegliere ordine e progettare filtri.
-

12) Indicatori per scelta d'ordine (ACF, PACF)

- **ACF (autocorrelation function)**: per $MA(n_c)$ si annulla dopo n_c lags $\rightarrow$ utile per sospettare un MA.
 - **PACF (partial autocorrelation)**: per $AR(n_a)$ la PACF è zero per lag $> n_a \rightarrow$ utile per sospettare AR.
 - Regola pratica (Box-Jenkins): usare ACF + PACF per ipotizzare struttura AR/MA/ARMA.
-

13) Periodogramma: dettagli pratici (bias/varianza/leakage)

- Il periodogramma è semplicissimo da calcolare (DFT e modulo quadro) ma ha **alta varianza** e problemi di leakage.
 - **Windowing** in tempo (prima di calcolare DFT) riduce leakage (side-lobes) ma allarga la main-lobe (peggiora risoluzione).
 - **Welch**: riduce la varianza mediando periodogrammi di segmenti (trade-off risoluzione/varianza).
 - **Blackman–Tukey**: stima autocovarianza fino a lag max e prende DTFT di quella finestrata $\rightarrow$ controlla smoothing in frequenza.
-

14) Note pratiche di identificazione / identifiability (richiami dalle slide)

- Esistono ridondanze: es. in MA si può moltiplicare $C(z)$ per α e dividere σ_e^2 per α^2 lasciando il processo invariato. Per questo spesso si fissa $c_0 = 1$ per evitare sovrapparametrizzazione.
 - Stabilità (poli) e invertibilità (zeri nel MA) sono concetti importanti durante la scelta del modello e la stima.
-

15) Esempio rapido (MA1) — come si calcola la PSD da γ

Prendiamo $y(t) = e(t) + c_1 e(t-1)$ con $e(t) \sim WN(0, 1)$:

- Autocovarianze:
 - $\gamma(0) = 1 + c_1^2$
 - $\gamma(1) = c_1$
 - $\gamma(\tau) = 0$ per $|\tau| > 1$.
- PSD:

$$\Gamma_{yy}(\omega) = 1 + 2c_1 \cos \omega + c_1^2 = |1 + c_1 e^{-j\omega}|^2.$$

Interpretazione: per $c_1 > 0$ si enfatizzano certe frequenze (basse), per $c_1 < 0$ si enfatizzano altre (alte).

16) Brevi raccomandazioni operative

- Prima di stimare un modello, **depola** (sottrai media) la serie se la media non è zero.
 - Esamina ACF e PACF per ipotesi d'ordine.
 - Per PSD preferisci stime con smoothing (Welch / Blackman–Tukey) per dataset finiti.
 - Scegli ARX se vuoi stima via LS (semplice), ARMAX/BJ se rumore strutturato (ma servono metodi numerici diversi, es. PEM).
-