

Linguaggi Formali e Compilatori

Argomento 01

Prof. Giuseppe Psaila

Laurea Magistrale in Ingegneria Informatica
Università di Bergamo

Un **TRADUTTORE** è un componente software che legge un testo scritto in uno specifico **Linguaggio Formale** e lo traduce

- o in un altro linguaggio formale
- o in azioni.

- Un **COMPILATORE** è un traduttore che traduce un linguaggio di programmazione nella corrispondente versione in linguaggio macchina (binaria).
- Un **INTERPRETE** è un traduttore che traduce un programma scritto in un linguaggio di programmazione in azioni (esegue direttamente il programma).

Organizzazione di un COMPILATORE

- **FRONT-END**: la parte del compilatore che analizza il testo.
- **BACK-END**: la parte che genera il codice binario della specifica piattaforma.

In questo modo, lo stesso Front-End può essere accoppiato a Back-End diversi (es. il g++ della GNU).

Struttura del Front-End

- **Scanner (Lexer)**: riconosce gli elementi lessicali del linguaggio
- **Parser (Analizzatore Sintattico)**: riconosce la struttura sintattica del linguaggio
- **Analizzatore Semantico**: dà un significato al testo, riconoscendo gli errori semantici

Ci occupiamo del Front-End, cioè della parte *linguistica* dei traduttori:

- **Ambito formale**

all'interno del quale le tecniche sono definite

- **Automi a Stati Finiti**

La tecnica usata per il riconoscimento lessicale

- **Strutture Sintattiche e Tecniche di Parsing**

Definire e riconoscere le strutture sintattiche di un linguaggio

- **Semantica dei Linguaggi**

Definire il significato dei linguaggi formali

(non necessari)

- Crespi-Reghizzi
Linguaggi Formali e Compilazione
Pitagora Editrice
- Aho, Lam, Sehi, Ullman
Compilatori
Principi, Tecniche e Strumenti
Pearson - Addison Wesley

- **6 CFU Linguaggi Formali**

Esame scritto

- **9 CFU Linguaggi Formali e Compilatori**

Esame scritto (fino a 26 punti)

Progetto semi-facoltativo (6 punti), impegno massimo
2 settimane

12 ore di esercitazioni per imparare a usare gli strumenti
di generazione automatica dei traduttori e impostare il
progetto

18 ore di tutorato (con me) per preparavi all'esame scritto

Aspetti Formali

- **Alfabeto**

Un **Alfabeto** è un **INSIEME FINITO** di **SIMBOLI**
o **CARATTERI TERMINALI**.

$$\Sigma = \{a_1, a_2, \dots, a_k\}$$

$|\Sigma| = k$ è la **Cardinalità** di Σ

- **Stringa**

Una **STRINGA** o **FORMA** è una **sequenza di caratteri terminali**.

Esempio: sia $\Sigma = \{a, b\}$

- *aa*
- *abab*
- *b*
- *baa*

sono stringhe

- La **lunghezza** di una stringa s , indicata come $|s|$, è il numero dei suoi caratteri
- La stringa ϵ (**Stringa VUOTA**) ha lunghezza 0, cioè $|\epsilon| = 0$
- Quindi, data una stringa s ,
 $|s| \geq 0$.
- Date due stringhe $x = a_1 a_2 \dots a_h$ e $y = b_1 b_2 \dots b_k$, esse si dicono **UGUALI** se $h = k$ e $a_i = b_i$ per ogni $i \in [1 \dots h]$.
Esempio: $aba \neq baa \neq ba$.

Un **Linguaggio** è un **Insieme di Stringhe**.

Esempi: $\Sigma = \{a, b\}$

- $L_1 = \{aa, aaa\}$
- $L_2 = \{aba, aab\}$
- $L_3 =$ insieme delle stringhe che contengono un ugual numero di a e di b
 $= \{ab, ba, aabb, \dots\}$

- La **CARDINALITÀ** di un linguaggio L è il numero delle sue stringhe. Si indica come $|L|$.
- Un linguaggio avente cardinalità **FINITA** (risp. **INFINITA**) è detto **Linguaggio FINITO** (risp. **Linguaggio INFINITO**).
- Una stringa s appartenente ad un linguaggio L è detta **Frase di L** ;
una stringa s che **non appartiene** ad un linguaggio L è detta **NON FRASE** di L , o **Stringa Scorretta** per L .
- $L = \emptyset$ è un caso particolare di linguaggio finito, detto **Linguaggio VUOTO** ($|\emptyset| = 0$).

Esempi

- $L_1 = \{aa, aaa\}$
 $|L_1| = 2$, finito.
 $s_1 = aa$ è frase di L_1 .
 $s_2 = ab$ è non frase di L_1 .
- $L_3 =$ insieme delle stringhe contenenti un ugual numero di a e di b
 L_3 è infinito.
 $s_1 = aa$ è non frase di L_3 .
 $s_2 = ab$ è frase di L_3 .

Concatenamento

Date due stringhe $x = a_1a_2 \dots a_h$ e $y = b_1b_2 \dots b_k$,

$$x \bullet y = a_1a_2 \dots a_hb_1b_2 \dots b_k$$

che si scrive anche $xy = x \bullet y$.

Proprietà del Concatenamento

- Il concatenamento **non è commutativo**.
 $xy \neq yx$ in generale.
- Il concatenamento è **associativo**.
 $(xy)z = x(yz)$
- La lunghezza del concatenamento è **la somma delle lunghezze**.
 $|xy| = |x| + |y|$

La stringa vuota ϵ è **l'elemento neutro rispetto al concatenamento**, $x \bullet \epsilon = \epsilon \bullet x = x$, con

$$|x \bullet \epsilon| = |x| + |\epsilon| = |x| + 0 = |x| \text{ e}$$

$$|\epsilon \bullet x| = |\epsilon| + |x| = 0 + |x| = |x|$$

SottoStringhe

Sia $x = uyz$, dove u , y e z sono stringhe.

- u , y , z sono **sottostringhe** di x .
- u è un **Prefisso** di x .
- z è un **Suffisso** di x .

Una sottostringa si dice **PROPRIA** se non coincide con la stringa che la contiene.

Prefissi

- Sia x una stringa di lunghezza **almeno** k , cioè $|x| \geq k$.
- Con $k : x$ si indica il prefisso di x avente lunghezza k .
- $u = k : x$ e $x = uz$, con $|u| = k$.
- $k : x$ è detto **l'inizio di x di lunghezza k** .

Esercizio 1.1: $\Sigma = \{a, b, c\}$, $x = aabacba$

- Prefissi:
- Suffissi:
- Altre sottostringhe (non prefissi e non suffissi):
- $3 : aabacba =$

Riflessione

Data una stringa $x = a_1 a_2 \dots a_h$
la stringa **RIFLESSA** x^R è $x^R = a_h \dots a_2 a_1$.

Proprietà

- $(x^R)^R = x$
- $(xy)^R = y^R x^R$
- $\epsilon^R = \epsilon$

Esempi

$x = ROMA$ $x^R = AMOR$

$x = OMAR$ $x^R = RAMO$

$x = OTTO$ $x^R = OTTO$

$x = UNO$ $x^R = ONU$

Ripetizioni - Elevamento a Potenza

La **POTENZA** n -sima (con $n \geq 0$ **intero**) di una stringa x

è il **concatenamento di x con se stessa $n - 1$ volte**.

Formalmente:

- $x^n = x^{n-1} \bullet x$ per $n > 0$
- $x^0 = \epsilon$

L'elevamento a potenza e la riflessione hanno precedenza rispetto al concatenamento.

Esercizio 1.2: $\Sigma = \{a, b\}$

- $x = ab$

$$x^0 =$$

$$x^1 =$$

$$x^2 =$$

- $y = a^2$

$$y^3 =$$

- $\epsilon^0 =$

$$\epsilon^3 =$$

Esercizio 1.3: $\Sigma = \{a, b\}$

- $x = ab^2 =$
 $y = (ab)^2 =$
- $x = ab^R =$
 $y = (ab)^R =$

Concatenamento

Dati **due linguaggi** L_1 e L_2 ,

$$L = L_1 \bullet L_2 = \{xy \mid x \in L_1 \text{ AND } y \in L_2\}.$$

Inizi

Dato un linguaggio L e un numero $k > 0$ intero,
 $k : L = \{y \mid y = k : x \text{ AND } x \in L \text{ AND } |x| \geq k\}$,
detto **Linguaggio degli Inizi di Lunghezza k di L** .

Prefissi

Dato un linguaggio L ,

$$\text{Prefissi}(L) = \{y \mid x = yz \text{ AND } x \in L \text{ AND } z \neq \epsilon\},$$

detto il **Linguaggio dei Prefissi (Propri)** di L .

Un linguaggio L è detto **PRIVO DI PREFISSI** se
Nessuno dei Suoi Prefissi è contenuto in L .

Formalmente: $\text{Prefissi}(L) \cap L = \emptyset$.

Esercizio 1.4

- Dato $\Sigma = \{a, b\}$, e $L = \{a^n b^n \mid n \geq 1\}$,
 $\text{Prefissi}(L) \cap L =$
- Dato $\Sigma = \{a, b\}$, e $L = \{a^m b^n \mid m > n \geq 1\}$,
 $\text{Prefissi}(L) \cap L =$

Riflessione

Dato un linguaggio L ,

$$L^R = \{x \mid y \in L \text{ AND } x = y^R\}.$$

Ripetizione / Potenza

Dato un linguaggio L e un numero $n \geq 0$ intero, la **Potenza n -sima di L** è

- $L^n = L^{n-1} \bullet L$ se $n > 0$
- $L^0 = \{\epsilon\}$

Casi Particolari

- $L^0 = \{\epsilon\} \neq \emptyset$
infatti $|\{\epsilon\}| = 1$, mentre $|\emptyset| = 0$
- $\emptyset^0 = \{\epsilon\}$
- $L \bullet \emptyset = \emptyset$
 $\emptyset$ è l'elemento **ZERO** rispetto al concatenamento di linguaggi
- $L \bullet \{\epsilon\} = L$
 $\{\epsilon\}$ è l'elemento **NEUTRO** rispetto al concatenamento di linguaggi

Esercizio 1.5

Si considerino i linguaggi

- $L_1 = \{a^i \mid i \geq 0 \text{ PARI}\} = \{\epsilon, aa, aaaa, \dots\}$
- $L_2 = \{b^j a \mid j \geq 1 \text{ DISPARI}\} = \{ba, bbba, \dots\}$

Che cosa Risulta?

- $L_1 \bullet L_2 =$
- $L_1 \bullet L_1 = L_1^2 =$

Esempio

Dato l'alfabeto $\Sigma = \{a, b\}$, il linguaggio delle stringhe x con lunghezza $0 \leq |x| \leq 2$ è definito come

$$L = \{\epsilon, a, b\}^2.$$

Per un generico $n \geq 1$

$$L = \{\epsilon, a, b\}^n.$$

Operatore STELLA

Chiusura Riflessiva al Concatenamento

$$L^* = \bigcup_{h=0 \dots \infty} L^h = \{\epsilon\} \cup L^1 \cup L^2 \cup \dots$$

Esercizio 1.6

- Dato $L = \{ab, ba\}$,
 $L^* =$
- Dato $L = \{a^{2n} \mid n \geq 0\}$,
 $L^* =$

Monoide Libero

Dato un alfabeto Σ e un linguaggio $L = \Sigma$ (linguaggio dei simboli terminali)

Σ^* **contiene tutte le stringhe che possono essere costruite concatenando i caratteri terminali.**

Ogni linguaggio formale L di alfabeto Σ è incluso in Σ^* ,
 $L \subseteq \Sigma^*$.

Proprietà

- $L \subseteq L^*$ (Monotonicità)
- Se $x \in L^*$ e $y \in L^*$,
allora $xy \in L^*$ (Chiusura rispetto al concatenamento)
- $(L^*)^* = L^*$ (Idempotenza)
- $(L^*)^R = (L^R)^*$ (Commutatività della stella e della riflessione)

Casi Particolari

- $\emptyset^* = \{\epsilon\}$
- $\{\epsilon\}^* = \{\epsilon\}$

Esercizio 1.7

Definiamo il **linguaggio degli identificatori**.

- Consideriamo due alfabeti $\Sigma_1 = \{A, B, C, \dots, Z\}$ e $\Sigma_2 = \{0, 1, 2, \dots, 9\}$, con l'alfabeto generale $\Sigma = \Sigma_1 \cup \Sigma_2$.
- Un identificatore è una stringa che inizia con una lettera alfabetica (in Σ_1) e contiene un numero arbitrario di lettere e numeri (ma non è vuota).
- $L = \dots$

Operatore CROCE

Chiusura Non Riflessiva al Concatenamento

$$L^+ = \bigcup_{h=1 \dots \infty} L^h = L^1 \cup L^2 \cup \dots$$

Proprietà

- $L^* = L^+ \cup \{\epsilon\}$
- $L^+ = L \bullet L^* = L^* \bullet L$

La stringa vuota ϵ compare in L^+ solo se è già in L .

Esercizio 1.8

Si consideri $L = \{\epsilon, aa\}$.
Che linguaggio è L^+ ?

Operatori Insiemistici

- $L_1 \cup L_2$ Unione
- $L_1 \cap L_2$ Intersezione
- $L_1 - L_2$ Differenza

Confronti

- $L_1 \subseteq L_2$ Inclusione
- $L_1 \subset L_2$ Inclusione propria
- $L_1 = L_2$ Uguaglianza

Complemento

Dato l'alfabeto Σ ,

$$\neg L = \Sigma^* - L = \{x \mid x \in \Sigma^* \text{ AND } x \notin L\}.$$

Esercizio 1.9

Si consideri $L = \{a^{2^n} \mid n \geq 0\}$, con $\Sigma = \{a\}$.

$\neg L = \dots$

Esercizio 1.10

Si consideri $\Sigma_1 = \{a, b, c\}$ e $\Sigma_2 = \{a, b\}$.

$$(\Sigma_1)^* - (\Sigma_2)^* = \dots$$

Sostituzione

Si considerino due alfabeti Σ e Δ e i linguaggi $L \subseteq \Sigma^*$ (**Linguaggio Sorgente**) $L' \subseteq \Delta^*$ (**Linguaggio Pozzo**). La **sostituzione di L' al posto di un carattere $b \in \Sigma$ nella stringa $x = a_1 a_2 \dots a_h$ produce il linguaggio di alfabeto $(\Sigma - \{b\}) \cup \Delta$, così definita:**

$$\begin{aligned}\phi_{b \rightarrow L'}(x) &= \\ &= \{y \mid x = a_1 a_2 \dots a_n \in L \text{ AND } y = c_1 c_2 \dots c_n \text{ AND} \\ &\quad \forall 1 \leq i \leq n (\text{IF } a_i \neq b \text{ THEN } c_i = a_i \text{ ELSE } c_i \in L')\}\end{aligned}$$

Se b e L' sono sottintesi, si indica $\phi(x)$.

Per l'intero linguaggio L , $\phi(L) = \cup_{(x \in L)} (\phi(x))$.

Esempio

Si considerino $\Sigma = \{a, b, c\}$ e $\Delta = \{x, y\}$.
 $L = \{a, b, ac, cb\}$ e $L' = \{x, y, xy\}$.

- $\phi_{c \rightarrow L'}(ac) = \{ax, ay, axy\}$
- $\phi_{c \rightarrow L'}(cb) = \{xb, yb, xyb\}$
- $\phi(L) = \{a, b, ax, ay, axy, xb, yb, xyb\}$